



PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS

Bacharelado em Engenharia de Computação

André Dias dos Santos Júnior

**LOCALIZAÇÃO E CLASSIFICAÇÃO DE OBJETOS
USANDO REDES NEURAIS CONVOLUTIVAS**

Belo Horizonte

31 de Maio de 2019

André Dias dos Santos Júnior

LOCALIZAÇÃO E CLASSIFICAÇÃO DE OBJETOS USANDO REDES NEURAIS CONVOLUTIVAS

Monografia apresentado ao Curso de Bacharelado em Engenharia de Computação da Pontifícia Universidade Católica de Minas Gerais, como requisito parcial para obtenção do título de Bacharel em Engenharia de Computação.

Orientador: Dr. Zenilton Kléber Gonçalves do Patrocínio Júnior

Belo Horizonte

31 de Maio de 2019

FICHA CATALOGRÁFICA
Elaborada pela Biblioteca da Pontifícia Universidade Católica de Minas Gerais



André Dias dos Santos Júnior

LOCALIZAÇÃO E CLASSIFICAÇÃO DE OBJETOS USANDO REDES NEURAIS CONVOLUTIVAS

Monografia apresentado ao Curso de Bacharelado em Engenharia de Computação da Pontifícia Universidade Católica de Minas Gerais, como requisito parcial para obtenção do título de Bacharel em Engenharia de Computação.

Prof. Dr. Zenilton Kléber Gonçalves do
Patrocínio Júnior – PUC Minas

Prof. Dr. Membro interno – PUC Minas

Prof. Dr. Membro externo – Instituição

Belo Horizonte, 31 de Maio de 2019.

À minha amada avó, que sempre me apoiou.

AGRADECIMENTOS

Em primeiro lugar, agradeço a Deus, que me deu forças para prosseguir, mediante aos obstáculos.

Agradeço também à minha avó por ter me apoiado incondicionalmente e por ter sempre acreditado em mim.

Agradeço também à minha mãe por ser um suporte sólido e por sempre me apoiar quando precisei.

Agradeço também ao meu orientador, o professor Zenilton pelo apoio, a presença, o auxílio prestado e pelo aprendizado ao longo da minha jornada.

Agradeço ao meu pai por torcer por mim e pelas orações.

E agradeço à todos os familiares e amigos que, de alguma forma me auxiliaram ao longo deste caminho.

*“Quando eu era menino, falava como menino,
sentia como menino, discorria como menino,
mas, logo que cheguei a ser homem, acabei
com as coisas de menino.”*

I Coríntios 13:11

RESUMO

Atualmente há um expressivo crescimento no volume de conteúdo visual, como imagens e vídeos, disponíveis para utilização. As informações contidas em imagens e vídeos são utilizadas pelas mais variadas áreas da sociedade, como médica, industrial e, até mesmo, para fins pessoais. Todos os dias são estudados novos métodos computacionais para fazer recuperação e análise de imagens. Dois métodos que tem sido frequentemente estudados em conjunto são a localização e classificação de objetos. Arquiteturas de *Deep Learning* podem ser implementadas para fazer localização e classificação de objetos, obtendo bons resultados, porém possuem certas limitações como o tamanho dos objetos ou a resolução da imagem. Para contornar essa limitação, pretende-se acrescentar camadas de convolução ao final de uma rede convolutiva densa para fazer a localização dos objetos de diversos tamanhos de forma mais apurada. Após as camadas finais de Convolução, serão acrescentadas camadas de Deconvolução, para aumentar a escala dos mapas, e decodificar os resultados das convoluções de forma a aumentar precisão do resultado.

Palavras-chave: *Deep Learning*, Localização, Classificação, Convolução, Deconvolução.

ABSTRACT

Currently, there is an expressive growth in the volume of visual content, such as images and videos available for use. The information contained in images and videos are used by the most areas of society, such as medical, industry and even for personal purposes. Every day new computational methods for recovering and analyzing images are studied. Two methods that usually been studied together are the localization and classification of objects. Architectures of Deep Learning can be implemented to localize and classify objects, obtaining good results, however they have certain limitations such as the size of the objects or the resolution of the image. To avoid this limitation, it is intended to add convolution layers in the end of a Dense Convolutional Network to make the location of objects of different sizes more accurately. After the final Convolution layers, Deconvolution layers will be added to increase the scale of the maps, and to decode the results of the convolutions in order to increase the accuracy of the result.

Keywords: Deep Learning, Localization, Classification, Convolution, Deconvolution.

LISTA DE FIGURAS

FIGURA 1 – Exemplo de Classificação e Localização	9
FIGURA 2 – Exemplo de bloco residual	11
FIGURA 3 – Exemplo de bloco denso	11
FIGURA 4 – Arquitetura DenseNet	23
FIGURA 5 – YOLO e SSD	24
FIGURA 6 – SSD e DSSD	25
FIGURA 7 – Módulos de predição SSD com ResNet	25
FIGURA 8 – Módulos de deconvolução	26
FIGURA 9 – Imagens PASCAL VOC 2007	28
FIGURA 10 – Resultado dos testes 1	32
FIGURA 11 – Resultado dos testes 2	33
FIGURA 12 – Resultado dos testes 3	33
FIGURA 13 – Resultado dos testes 4	34
FIGURA 14 – Resultado dos testes 5	34

LISTA DE TABELAS

TABELA 1 – Pascal VOC 2007	27
TABELA 2 – Resultados SSD	35

LISTA DE ABREVIATURAS E SIGLAS

CNN – *Convolutional Neural Networks* - Redes Neurais Convolucionais

CVPR – *Conference on Computer Vision and Pattern Recognition* - Conferência de Visão Computacional e Reconhecimento de Padrões

DBN – *Deep Belief Networks*

DenseNet – *Densely Connected Convolutional Networks* - Redes Convolutivas Densamente conectadas

DSSD – *Deconvolutional Single-Shot Detector*

FCN – *Fully Convolutional Network* - Rede Completamente Convolucional

FPS – *Frames Per Second* - Quadros Por Segundo

ILSVRC – *ImageNet Large Scale Visual Recognition Challenge*

mAP – *Mean Average Precision* - Média da precisão Média

MLP – *Multi-Layer Perceptron*

MLS – *Mean Less Squares* - erro quadrático mínimo

PASCAL VOC – *PASCAL Visual Object Classes*

RBM – *Restricted Boltzmann Machines*

R-CNN – *Regions with CNN features*

ReLU – *Rectified Linear Unit* - Ativação Linear Retificada

ResNet – *Residual Network* - Rede Neural Residual

RNA – Rede Neural Artificial

SSD – *Single-Shot multi-box Detector*

YOLO – *You Only Look Once* - você só olha uma vez

SUMÁRIO

1	INTRODUÇÃO	9
1.1	Motivação	13
1.2	Objetivos	13
1.3	Justificativa	14
1.4	Organização do texto	14
2	REVISÃO BIBLIOGRÁFICA	16
2.1	<i>Machine Learning</i>	16
2.1.1	<i>Regressão</i>	16
2.1.2	<i>Classificação</i>	17
2.2	Redes Neurais Artificiais	18
2.2.1	<i>Multi-Layer Perceptron</i>	19
2.3	<i>Deep Learning</i>	20
2.3.1	<i>Redes Neurais Convolucionais</i>	21
3	TRABALHOS RELACIONADOS	22
3.1	DenseNet	22
3.2	SSD: <i>Single-Shot Multibox Detector</i>	23
3.3	DSSD: <i>Deconvolution Single-Shot Detector</i>	24
3.4	PASCAL VOC	26
3.4.1	<i>PASCAL VOC 2012</i>	28
4	PROPOSTA TÉCNICA	29
4.1	Metodologia	29
4.1.1	<i>Levantamento Bibliográfico</i>	29
4.1.2	<i>Testes e avaliações com métodos da literatura</i>	29
4.1.3	<i>Desenvolvimento do protótipo inicial</i>	29
4.1.4	<i>Desenvolvimento da arquitetura final usando deconvolução</i>	30
4.1.5	<i>Avaliação dos resultados e comparação com o Estado da Arte</i> ..	30


5	EXPERIMENTOS	31
5.1	SSD	31
5.1.1	<i>Treinamento</i>	31
5.1.2	<i>Avaliação Qualitativa</i>	32
5.1.3	<i>Avaliação Quantitativa</i>	35
6	CONCLUSÃO	37
6.1	Trabalhos Futuros	37
	REFERÊNCIAS	38

1 INTRODUÇÃO

Atualmente há um expressivo crescimento no volume de conteúdo visual, como imagens e vídeos, disponíveis para utilização. Podemos vincular este fato à popularização das tecnologias produtoras destes tipos de conteúdo, como celulares com câmeras, bem como a expansão da Internet e seus canais de comunicação, que utilizam de imagens e vídeos para divulgação de informações. As informações contidas em imagens e vídeos são utilizadas pelas mais variadas áreas da sociedade, como médica, industrial e, até mesmo, para fins pessoais e de entretenimento.

O processamento digital de imagens contribui para a descoberta de informação visual contida em imagens e vídeos. Um dos problemas de processamento digital de imagens amplamente explorados na literatura é o problema de classificação e localização de objetos em imagens. Everingham et al. (2015) definem que o problema de classificação consiste em responder para cada classe de objeto se existe ou não uma ou mais instâncias daquele objeto na imagem e, o problema de localização consiste em dizer onde na imagem estão as instâncias dos objetos reconhecidos pelo classificador.

Figura 1 – Exemplo de Classificação e Localização de Objetos



Fonte: Everingham et al. (2015).


A Figura 1 mostra exemplos de como devem ser as saídas de um algoritmo de classificação e localização de objetos. Os retângulos destacados em torno dos objetos são resultados do algoritmo de localização que determina que dentro daquela região existe um objeto de interesse e os rótulos destacados em cima dos retângulos são os resultados do algoritmo de classificação, que determina que o objeto contido dentro da região pertence àquela classe.

O uso das *Convolutional Neural Networks* - Redes Neurais Convolucionais (CNN) tem se tornado cada vez mais populares, principalmente em alguns dos problemas clássicos de processamento de imagens. A primeira abordagem desse tipo foi proposta por Fukushima (1980) para fazer reconhecimento de caracteres escritos a mão. Mais tarde, Lecun et al. (1998) desenvolveram uma arquitetura de CNN para a mesma tarefa e obtiveram uma acurácia de 70%, sendo essa muito superior aos resultados obtidos por qualquer outro classificador utilizado até então.

Contudo, as CNN só passaram a ser utilizadas com mais frequência algum tempo depois. Deng et al. (2009) lançaram o ImageNet, uma base de dados de larga escala com mais de 14 milhões de imagens anotadas manualmente divididas em mais de 22 mil classes diferentes. Essa base de imagens pode ser usada para as tarefas de classificação, detecção e localização de objetos. Além disso, Deng et al. (2009) também lançaram o *ImageNet Large Scale Visual Recognition Challenge* (ILSVRC), uma competição global anual, aonde os competidores são avaliados nas tarefas de classificação de imagens, detecção de objetos e localização de objetos. Krizhevsky, Sutskever e Hinton (2012) alcançaram o melhor resultado no ILSVRC de 2012 usando a AlexNet - uma CNN - e desde então, as CNNs obtêm sempre os melhores resultados nos desafios.

Em 2016, He et al. propuseram a *Residual Network* - Rede Neural Residual (ResNet) que introduziam o conceito de *skip connection*. Uma *skip connection* é quando a camada C_n além de se conectar com a camada C_{n+1} ela se conecta com outra mais a frente - no caso da *ResNet*, a camada C_{n+3} . Sendo assim, a camada C_{n+3} recebe em suas entradas uma junção das saídas de C_n e C_{n+2} . Essa combinação de entradas na ResNet foi feita como uma soma de matrizes. A Figura 2 mostra um exemplo de *skip connection* na *ResNet*.

Figura 2 – Exemplo de bloco residual




Fonte: He et al. (2016).

He et al. (2016) além de vencerem o ILSVRC de 2015, venceram o prêmio de melhor artigo na *Conference on Computer Vision and Pattern Recognition* - Conferência de Visão Computacional e Reconhecimento de Padrões (CVPR) de 2016.

Seguindo a mesma ideia de *skip connection* proposta por He et al. (2016), Huang et al. (2017) propuseram a *Densely Connected Convolutional Networks* - Redes Convolutivas Densamente conectadas (DenseNet). Nessa nova arquitetura houveram duas mudanças com relação à ResNet. A primeira mudança é que as saídas das camadas não seriam mais somadas, mas sim concatenadas, ou empilhadas. A segunda é que em um bloco residual as camadas se conectam com todas as suas sucessoras.

Figura 3 – Exemplo de bloco denso



Fonte: Huang et al. (2017).

A Figura 3 mostra como se conectam as camadas na DenseNet. Supondo que temos um bloco denso B com um conjunto de 5 camadas $C = \{c_1, c_2, c_3, c_4, c_5\}$. Como explicado no parágrafo anterior, a saída das camadas serão utilizadas em todas as camadas subsequentes no mesmo bloco. Sendo assim, a entrada de c_3 será composta pelas saídas de c_1 e c_2 concatenadas, e assim sucessivamente. Além disso, como as saídas são concatenadas e não somadas, a tendência é que as entradas cresçam a medida que a rede se aprofunda. O conceito de bloco denso permite propagar múltiplos níveis de abstração ao longo de

toda a rede, melhorando assim os resultados obtidos (Huang et al., 2017).

Huang et al. ficaram em segundo lugar no ILSVRC de 2017 e venceram o prêmio de melhor artigo da CVPR do mesmo ano.

Nas tarefas de localização de objetos as CNNs também têm se destacado com bons resultados. Redmon et al. (2015) propuseram o *You Only Look Once* - você só olha uma vez (YOLO) e obtiveram um bom resultado fazendo localização e classificação de objetos em tempo real, conseguindo processar 45 *Frames Per Second* - Quadros Por Segundo (FPS) com uma *Mean Average Precision* - Média da precisão Média (mAP) de 63,4%. Ren et al. (2017) propuseram o *Regions with CNN features* (R-CNN) e conseguiram obter resultados significativamente melhores para as tarefas de localização e classificação chegando a uma mAP de até 78,8%. Numa implementação alternativa com o enfoque no processamento em tempo real, a mAP cai um pouco, chegando a 73,2% porém, ele processa apenas 7 FPS.

Liu et al. (2015) propuseram o *Single-Shot multi-box Detector* (SSD), uma abordagem que além de obter uma mAP elevada (74,3%), supera a velocidade alcançada no YOLO atingindo 59 FPS. Esses resultados são especialmente relevantes, pois, além de serem competitivos com o estado da arte, trabalham com imagens menores - enquanto os quadros processados pelo YOLO têm dimensões 448×448 e os processados pelo R-CNN têm 1000×600 , o SSD processa quadros de dimensões 300×300 . O principal ganho em trabalhar com imagens menores é diminuir o consumo de memória e ter um método mais robusto por poder obter resultados competitivos mesmo que com imagens menores. Por um outro lado, trabalhar com imagens menores pode significar que o método seja mais lento ao processar imagens maiores.

Uma outra área impactada pelo uso das CNNs é a área de segmentação semântica. Long, Shelhamer e Darrell (2014) propuseram o uso de uma *Fully Convolutional Network* - Rede Completamente Convolutacional (FCN) para fazer segmentação semântica e conseguiram obter resultados superiores ao estado da arte, utilizando camadas de deconvolução para aumentar a resolução dos mapas de filtros gerados na saída da CNN. Noh, Hong e Han (2015) propuseram um trabalho mais avançado de forma a tratar algumas limitações encontradas por Long, Shelhamer e Darrell (2014). Essa arquitetura funciona com a estrutura de um *autoencoder*, usando as camadas de deconvolução que não servem para aumentar a resolução, mas para recuperar as informações da imagem de forma mais refinada, de forma a melhorar os resultados da segmentação.

Por fim, Fu et al. (2017) propôs uma abordagem alternativa na resolução dos problemas de localização e classificação de objetos utilizando camadas de deconvolução a *Deconvolutional Single-Shot Detector* (DSSD). A DSSD recebe essa sigla, pois é uma extensão do SSD (LIU et al., 2015). A diferença é que, ao final, ele acrescenta camadas de

deconvolução e, com os resultados das deconvoluções ele faz a classificação e a localização. Os resultados obtidos superam os apresentados pelo SSD em mAP, alcançando 81,5% embora, o DSSD perde na velocidade (13,6 FPS).

1.1 Motivação

Estudos envolvendo redes neurais convolucionais têm sido realizados com muita frequência tanto em áreas gerais, quanto aplicados à áreas específicas. Estudos vem sendo feitos para classificação de imagens (KRIZHEVSKY; SUTSKEVER; HINTON, 2012; SIMONYAN; ZISSERMAN, 2014), classificação e detecção de objetos Fu et al. (2017), Lin et al. (2014), segmentação de imagens Long, Shelhamer e Darrell (2014), Noh, Hong e Han (2015), segmentação de objetos em vídeos Caelles et al. (2017), Voigtlaender e Leibe (2017). Isso se deve aos bons resultados obtidos pelos métodos aplicados nas respectivas áreas.

Além disso, o problema de classificação e detecção de objetos tem sido aproveitado como solução para problemas mais específicos, como detecção facial (Yang; Jiachun, 2018), contagem de pessoas (Ren; Fang; Djahel, 2017) e detecção de pedestres (Lan et al., 2018).

Por fim o uso das camadas de deconvolução no método proposto traz boas expectativas, uma vez que já há resultados na literatura que mostram a sua eficiência (Noh; Hong; Han, 2015; FU et al., 2017). Em suma, pode-se dizer que o tema ainda tem muito que ser explorado, que a proposta é promissora, e que bons resultados podem trazer contribuições para trabalhos futuros.

1.2 Objetivos

O objetivo do trabalho é utilizar a rede DenseNet121 modificada com camadas adicionais de convolução e deconvolução para fazer detecção e classificação de objetos. Para isso, será necessário:

- Adaptar a CNN DenseNet (Huang et al., 2017) para fazer localização e classificação de forma similar à SSD;
- Alterar a arquitetura da rede inicial para receber camadas de deconvolução de forma a melhorar os resultados da classificação e da Localização;
- Avaliar os resultados obtidos comparando-os com a literatura.

1.3 Justificativa

Com os avanços tecnológicos alcançados ao longo das últimas décadas, a produção de conteúdo multimídia tem crescido consideravelmente e tem sido amplamente explorada pelos mais diversos setores da sociedade. Todos os dias mais de 95 milhões de fotos e vídeos são postadas no Instagram*. Esse imenso volume de dados que são produzidos e acessados em multimídia inviabiliza a manipulação deste conteúdo por meio de ação humana; criando assim, a necessidade de automatizar a recuperação e análise de informações relevantes contidas nas mesmas.

Nesse sentido, todos os dias são estudados novos algoritmos e novas técnicas para fazer recuperação de informação multimídia. E uma das formas amplamente utilizadas é a de localização e classificação de objetos em imagens. Everingham et al. (2015) definem que o problema de classificação consiste em responder para cada classe de objeto se existe ou não uma ou mais instâncias daquele objeto na imagem e, o problema de localização consiste em dizer onde na imagem estão as instâncias dos objetos reconhecidos pelo classificador.

É válido estabelecer que “os mecanismos sensitivos dos seres humanos (como visão e audição) sugerem a necessidade de uma arquitetura profunda para extrair a sua estrutura complexa” (DENG; YU, 2014). Porém, de acordo com Caelles et al. (2017), uma grande limitação ao utilizar arquiteturas de DEEP LEARNING é a necessidade de treinamento com um grande volume de dados. Essa limitação torna o processo mais custoso em termos de tempo de processamento e outros recursos computacionais (como memória). Além disso, a base de dados deve ter os resultados da classificação e localização esperados feitos de forma manual, o que aumenta o esforço humano.

Tendo isso em vista, a proposta de utilizar a DenseNet (Huang et al., 2017) pré-treinada em classificação de imagens visa diminuir o custo por meio do *Transfer Learning*. Além disso, utilizando as camadas adicionais de deconvolução como proposto por Fu et al. (2017), espera-se obter resultados ainda melhores. Esses resultados melhores repercutiriam de forma positiva em outras áreas relacionadas à localização e classificação de objetos.

1.4 Organização do texto

O Capítulo 2 traz os principais conceitos relacionados à *Deep Learning*, redes neurais artificiais, classificação de objetos em imagens e detecção de objetos em imagens, necessários à compreensão do trabalho. O Capítulo 3 contém um resumo dos trabalhos

*<https://www.instagram.com>

relacionados à monografia. O Capítulo 4 contém a metodologia a ser seguida para o desenvolvimento do trabalho. Além disso contém um cronograma a ser seguido e a definição das métricas a ser utilizadas para avaliar os resultados obtidos. O Capítulo 5 descreve os experimentos realizados e os resultados obtidos. O Capítulo 6 apresenta a conclusão do trabalho com base nos resultados obtidos e apresenta propostas de trabalhos futuros.

2 REVISÃO BIBLIOGRÁFICA

2.1 *Machine Learning*

Machine Learning ou Aprendizado de Máquina é um campo de estudo cada vez mais recorrente na área de tecnologia. Em uma definição alternativa, pode-se dizer que “Aprendizado de Máquina é uma área de Inteligência Artificial cujo objetivo é o desenvolvimento de técnicas computacionais sobre o aprendizado bem como a construção de sistemas capazes de adquirir conhecimento de forma automática” (MONARD; BARANAUSKAS, 2003). Entre as principais aplicações de Aprendizado de máquina, pode-se destacar o reconhecimento de padrões, classificação de imagens e a mineração de dados.

Monard e Baranauskas (2003) definem ainda que o aprendizado de máquina pode ser supervisionado ou não-supervisionado. Quando falamos do primeiro caso, queremos dizer que o algoritmo recebe um conjunto de dados na entrada, processa esses dados e retorna uma saída. Essa saída é comparada com um valor previamente associado à entrada, comumente conhecido como rótulo. Já no aprendizado não-supervisionado, as entradas não possuem rótulo algum, cabendo ao algoritmo fazer a distinção das diversas entradas. Geralmente, nesses casos é necessária uma análise posterior à execução do algoritmo para se entender os resultados obtidos.

O aprendizado supervisionado se divide em dois grupos menores: classificação e regressão. Santos (2012) define que quando o problema possui um conjunto discreto de saídas e o objetivo é atribuir a qual dessas saídas a entrada pertence, se trata de um problema de classificação. Santos (2012) define ainda que quando o objetivo é prever uma saída de valor contínuo para uma entrada, se trata de um problema de regressão.

As seções 2.1.1 e 2.1.2 irão definir melhor esses conceitos.

2.1.1 *Regressão*

Como definido anteriormente, o problema de regressão consiste em calcular para cada entrada uma saída que possua um valor contínuo. Dosualdo (2003) define que a regressão consiste em fazer uma relação entre os atributos $X = x_1, x_2, \dots, x_n$ - onde X é o conjunto de entrada e cada x_i é um atributo numérico ou quantitativo - e Y , tal que Y é um atributo ou um conjunto de atributos meta. Apté e Weiss (1997) definem essa relação através da Equação 2.1.

$$Y = f(x_1, x_2, \dots, x_n) \quad (2.1)$$

A relação entre o(s) atributo(s) X e o(s) atributo(s)-meta Y alcançada como resultado de um algoritmo de regressão é chamado de modelo. Após a definição do modelo é importante fazer uma avaliação para dizer o quão confiável será a predição gerada pelo modelo. Existem diversas funções usadas na avaliação dos algoritmos de regressão, e uma das mais comuns é o *Mean Less Squares* - erro quadrático mínimo (MLS) que é definido pela Equação 2.2.

$$E = \sum_{i=0}^N (Y_i - f(X)_i)^2 \quad (2.2)$$

Em que E é o erro, N é o tamanho do conjunto de amostras, Y_i é o valor esperado do atributo-meta e $f(X)_i$ é o resultado do modelo para a entrada X_i .

Alguns exemplos de problemas de regressão são:

1. Predizer o percentual de gordura que uma pessoa possui no corpo, recebendo como entrada atributos como altura, idade, peso, sexo (DOSUALDO, 2003);
2. Predizer o preço de um imóvel baseado em atributos como o tamanho, número de cômodos, número de quartos, etc. (PEREIRA; GARSON; ARAÚJO, 2012).

Uma grande limitação nos métodos de regressão é que eles em sua maioria solucionam problemas que possuem apenas um atributo-meta. Porém, os métodos de regressão baseados em Rede Neural Artificial (RNA) podem retornar múltiplos resultados. Esse termo será definido na Sessão 2.2.

2.1.2 Classificação

Como definido anteriormente, o problema de classificação consiste em um problema de predição quando as saídas são discretas. A ideia dos algoritmos de classificação é definir para cada entrada, um rótulo ou classe no meio de um conjunto finito de rótulos. Um método estatístico muito utilizado nos problemas de classificação é a regressão logística. A regressão logística é bem similar à regressão linear, com a diferença que o resultado é um número entre zero e um, configurando na verdade, a probabilidade de, dado uma entrada X tal que $X = x_1, x_2, \dots, x_n$ gerar uma saída verdadeira para a hipótese Y . Normalmente, os modelos de regressão logística aplica a função sigmóide, descrita pela Equação 2.3.

$$Y = \frac{1}{1 + e^{-g(X)}} \quad (2.3)$$

A regressão logística se ajusta muito bem a problemas de classificação binária. Porém, a grande maioria dos problemas de classificação possuem mais de uma classe,

consistindo então em dizer para uma entrada X tal que $X = [x_1, x_2, \dots, x_n]$ a qual classe de Y ela pertence, tal que $Y = [y_1, y_2, \dots, y_m]$. Do e Poulet (2015) afirmam que as principais abordagens para solucionar problemas de classificação com M classes consistem em dividir o problema em vários problemas de classificação binária.

Essa divisão pode ser feita de duas formas diferentes:

- A primeira consiste em gerar $M - 1$ problemas de classificação binária e resolver cada um de forma independente. Após resolver os problemas de classificação, determinar a classe final a partir das probabilidades obtidas selecionando a classe que obteve a maior probabilidade. Essa abordagem é conhecida como *one-versus-all*.
- A segunda consiste em combinar as classes em pares e, para cada par de classe gerar um problema de classificação. Isto é, seja Y um conjunto de classes, para cada classe $y \in Y$ criar um problema de classificação para y e cada y_β tal que $y_\beta \in Y - [y]$. Isso gera um conjunto de $\frac{M(M-1)}{2}$ problemas de classificação. Após gerar e solucionar os problemas, o resultado será a classe que for mais vezes selecionada.

Com base na primeira abordagem, começou a ser utilizada uma função para os problemas de classificação que envolvem múltiplas classes. Essa função é a *softmax* que calcula o valor de cada saída e divide pela soma das saídas, gerando assim uma saída normalizada que corresponde à probabilidade de o dado de entrada estar na classe. Atualmente é a função mais utilizada para problemas de classificação com múltiplas classes e é descrita pela Equação 2.4.

$$f(x)_i = \frac{e^{\beta x_i}}{\sum_{j=1}^K e^{\beta x_j}} \forall i = 1, \dots, K \text{ e } x = x_1, \dots, x_k \in X^K \quad (2.4)$$

Assim como na regressão linear, a perda na regressão logística pode ser calculado pelo MLS. Porém, com o tempo, surgiram outras funções que calculam a perda de forma mais eficiente em problemas de classificação.

2.2 Redes Neurais Artificiais

As RNA são uma das principais técnicas de aprendizagem de máquina e podem ser implementadas tanto para problemas supervisionados, quanto não-supervisionados. Jost (2015) definiu as RNAs da seguinte forma:

As RNAs possuem inspiração nas redes neurais biológicas, constituídas de neurônios separados por camadas, que processam informações e estão conectados via pesos sinápticos, sendo na maioria das vezes sistemas

adaptativos que modificam sua estrutura através de informações, que fluem pela rede durante a etapa de aprendizado (JOST, 2015).

Além disso, é importante mencionar que em uma rede neural, existem duas camadas em particular que são muito importantes: a primeira camada, que é a camada de entrada de dados, e a última camada que é a camada de saída. Existem dois tipos de RNAs: as redes *feed forward*, que processa apenas o estado atual das entradas, e as redes neurais recorrentes que processa o estado atual e o estado anterior. As redes neurais recorrentes podem ser usadas de forma eficiente para processar vídeos, séries temporais e outros dados que possuam múltiplos estados.

A RNA *feed forward* mais básica que existe é a *Perceptron*, composta apenas por um conjunto de neurônios de entrada e um único neurônio de saída. A Equação 2.5 representa a fórmula de um *Perceptron*, onde n é o número de entradas, W_i são os respectivos pesos de cada entrada, X_i são as entradas e B é o viés do neurônio.

$$Y = \left(\sum_{i=1}^n (W_i \times X_i) \right) - B \quad (2.5)$$

Uma rede perceptron não é uma arquitetura de redes neurais artificiais muito poderosa, mas deu base para outras arquiteturas mais robustas. A principal delas é o *Perceptron* Multi-Camadas.

2.2.1 *Multi-Layer Perceptron*

As redes *Perceptron* Multicamadas ou *Multi-Layer Perceptron* (MLP) são baseadas nos *Perceptrons* simples, como mencionado anteriormente. A diferença, porém, é que elas trabalham com mais camadas do que simplesmente as camadas de entrada e saída. Geralmente elas possuem uma ou duas camadas intermediárias às camadas externas. Essas camadas intermediárias, também são chamadas de camadas ocultas e servem para conferir uma robustez maior ao método.

Nas MLPs, uma outra diferença é que as funções de ativação podem variar. As mais comuns são o *Rectified Linear Unit* - Ativação Linear Retificada (ReLU) (definido pela Equação 2.6), a função sigmóide (descrita na Seção 2.1.2) e a tangente hiperbólica (definida pela Equação 2.7).

$$Y(x) = \max(0, x) \quad (2.6)$$

$$Y(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.7)$$

Como foi dito anteriormente, a MLP trabalha com aprendizado supervisionado, isso quer dizer que os dados que ela opera são rotulados, e tem uma saída esperada. Quando as entradas são processadas e os resultados das saídas são calculados, eles são comparados com os valores esperados pelos rótulos e é gerado a função de erro quadrático, definida na Seção 2.1.1.

Sabendo-se disso, o objetivo para melhorar a precisão da MLP é minimizar o valor da função erro, ou seja, tornar as saídas da rede o mais próximo possível das saídas esperadas. Para tanto, é utilizado o método de retropropagação de erro que reajusta os pesos da rede de acordo com os valores obtidos usando a descida de gradiente.

Arnold et al. (2011) definem que aumentar o número de camadas em um MLP não garante uma melhoria dos resultados, pois a descida de gradiente pode chegar a um mínimo local. Além disso, o aumento do número de camadas implica em um tempo muito maior de processamento. Para lidar com esse problema surge o DEEP LEARNING, uma arquitetura avançada com múltiplas camadas, que soluciona a dificuldade que as redes neurais possuem ao lidar com dados de alta dimensionalidade (ARNOLD et al., 2011).

2.3 *Deep Learning*

A princípio não parecia ser viável manipular arquiteturas profundas de redes neurais. Porém, de acordo com Deng e Yu (2014), surgiu um algoritmo de aprendizado não-supervisionado que conseguiu aliviar empiricamente as dificuldades de otimização em arquiteturas profundas. Esse algoritmo é a *Deep Belief Networks* (DBN), um modelo generativo profundo composto de uma camada visível e várias camadas ocultas compostas por uma pilha de *Restricted Boltzmann Machines* (RBM)s.

Deng e Yu (2014) definem ainda que o aprendizado nas DBNs é feito por um algoritmo guloso que ajusta os pesos camada-por-camada com uma complexidade linear ao tamanho e à profundidade da rede. E uma relação inesperada entre as DBNs e as MLPs surgiu quando descobriu-se que ao utilizar os pesos de uma DBN com arquitetura correspondente, você consegue inicializar os pesos de uma MLP de forma a produzir melhores resultados do que utilizando pesos aleatórios.

Uma segunda alternativa para trabalhar com aumento de camadas é o empilhamento de auto-codificadores. O empilhamento de auto-codificadores consiste basicamente em inserir na saída de uma rede neural uma segunda rede neural que para cada entrada produz uma saída específica e retrainar a nova rede neural utilizando o algoritmo de retropropagação de erro (DENG; YU, 2014).

2.3.1 *Redes Neurais Convolucionais*

As CNN são um modelo específico de *Deep Learning* muito utilizados em aplicações de visão computacional e aplicações de reconhecimento de imagens. De acordo com Ferreira (2017), as CNNs utilizam matrizes para processar as entradas de dados, sendo essas matrizes unidimensionais para sinais e sequências, bidimensionais para imagens e tridimensionais para imagens volumétricas e vídeos.

Ao contrário das RNAs tradicionais (como MLP), as CNNs não necessariamente ligam todos os neurônios na camada de origem a todos os neurônios da camada de destino. Ferreira (2017) define que existem três tipos comuns de camadas utilizadas nas redes neurais convolucionais: as camadas de convolução, camadas de *pooling* e camadas completamente conexas.

A ideia da camada de convolução é de que cada neurônio recebe como entrada neurônios próximos e tem por objetivo criar mapas e filtros. Ferreira (2017) define que em aplicações de reconhecimento de objetos, por exemplo, é comum as primeiras camadas de convolução detectarem bordas ou manchas que seriam as características mais básicas da imagem. As camadas de convolução mais profundas detectam outras características mais específicas.

As camadas de *pooling* são utilizadas para reduzir a dimensão de dados vindo das camadas de convolução, conseqüentemente reduzindo o custo computacional (FERREIRA, 2017). Na prática elas funcionam como as camadas de convolução, mas ao invés de fazer a operação tradicional de convolução, elas reduzem um conjunto de elementos a um único representante com base em uma função específica. As funções mais utilizadas são máximo e média (FERREIRA, 2017).

Por fim, as camadas completamente conexas são exatamente iguais às redes MLP e é comum utilizá-las no final da rede para conectar à saída. Seu acréscimo no final é importante pois faz a ligação de todos os filtros (FERREIRA, 2017). As arquiteturas de CNNs geralmente intercalam algumas camadas de convolução com uma camada de *pooling*. As arquiteturas mais antigas costumavam adicionar camadas completamente conexas ao final, porém, os modelos mais novos, como a ResNet e a DenseNet já não usam mais esse conceito.

3 TRABALHOS RELACIONADOS

3.1 DenseNet

Como mencionado anteriormente, desde 2012 as tarefas de classificação de imagens são resolvidas majoritariamente por arquiteturas de *Deep Learning*. He et al. (2016) propôs uma nova arquitetura que utilizava o conceito de *skip connection*, que, como explicado anteriormente, consiste em utilizar a saída de uma camada em camadas posteriores além da próxima. O conceito de *skip connection* fez tanto sucesso que tornou a ser utilizado em um modelo mais recente. (Huang et al., 2017) propuseram um modelo de CNN que utiliza esse mesmo conceito, porém de uma forma um pouco diferente.

Nas ResNets, existem os blocos residuais, conforme a figura 2. No bloco residual temos duas camadas c_1 e c_2 onde c_1 é a entrada de c_2 . Na saída deste bloco residual será feita uma soma de matrizes entre a saída de c_2 e a entrada de c_1 e essa soma será usada na entrada das camadas posteriores.

Nas DenseNets, o conceito de *skip connection* é utilizado conforme a Figura 3. Um bloco denso B composto por um conjunto de camadas $C = \{c_1, c_2, \dots, c_n\}$ onde c_1 é a entrada de c_2 . A primeira diferença é que para as camadas sucessoras, todas as camadas anteriores estarão na entrada, isso é, a entrada de c_3 será $\{c_1, c_2\}$, a entrada de c_4 será $\{c_1, c_2, c_3\}$ e assim sucessivamente. A segunda diferença é que nos blocos densos as saídas das camadas são unidas por uma concatenação de matrizes, não por soma. Sendo assim, se cada camada do bloco possui uma saída de x matrizes, o bloco possui n camadas e a entrada do bloco possui tamanho a , a saída possuirá o tamanho representado pela Equação 3.1:


$$y = nx + a \quad (3.1)$$

Vale mencionar que o valor de x se conserva para toda a rede. Uma vantagem de usar blocos densos é a possibilidade de propagar informações com diversos níveis de abstração ao longo de toda a rede.

As DenseNets seguem um padrão arquitetural muito similar ao das ResNets começando a rede com uma camada de convolução 7×7 com *strides* de 2×2 que é sucedida por uma camada de *batch normalization* e outra de ReLU. Depois disso, têm uma camada de *pooling* máximo e após essa camada, têm quatro blocos densos intercalados por blocos

intermediários. Os blocos de convolução dentro dos blocos densos são compostos por uma camada de convolução 1×1 (que Huang et al. (2017) definem como camada de “gargalo”) e uma camada de convolução 3×3 . Vale mencionar que todas as camadas de convolução nos blocos densos são precedidas por uma camada de *batch normalization* e ReLU. Os blocos intermediários são compostos por uma camada de convolução 1×1 seguida de uma camada de *pooling* pela média (que também é precedida por *batch normalization* e ReLU). No final dos 4 blocos densos, a rede possui mais uma camada de *batch normalization* e ReLU seguida por um *pooling* pela média global e uma camada completamente conectada que faz a classificação. A Figura 4 mostra como é a arquitetura da rede.

Figura 4 – Arquitetura DenseNet



Fonte: Huang et al. (2017).

O modelo proposto obteve resultados competitivos com os da literatura, ficando em segundo lugar no ILSVRC de 2017 e apresentando resultados competitivos com os da literatura na época. O artigo também foi premiado como a melhor publicação da CVPR do ano de 2017. O modelo obteve uma acurácia de 96% na Cifar-10 e 82% na Cifar-100.

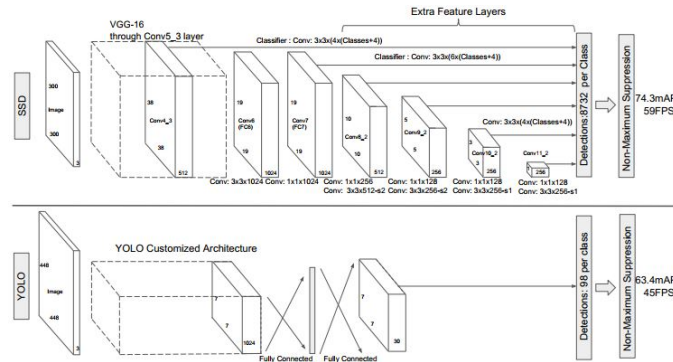
3.2 SSD: *Single-Shot Multibox Detector*

Liu et al. (2015) propuseram um método a base de redes neurais convolucionais para fazer a localização e detecção de objetos. A proposta deles melhorou significativamente os resultados apresentados no estado da arte. Isso se deve ao fato de que eles não só conseguiram propor um modelo que faz a localização e classificação de forma eficiente (chegando a 74,3% de mAP), como conseguiram obter esse resultado fazendo classificação e localização em tempo real, com uma velocidade de 59 FPS. Uma outra vantagem obtida por esse método é que ele consegue fazer a localização e classificação em imagens significativamente menores, uma vez que os quadros processados pelo YOLO têm dimensões 448×448 e os processados pelo R-CNN têm 1000×600 , o SSD processa quadros de dimensões 300×300 . Isso é uma vantagem, pois mesmo o algoritmo trabalhando com imagens menores, o resultado consegue competir com os outros métodos.

A abordagem consiste em utilizar a rede VGG16 (SIMONYAN; ZISSERMAN, 2014) como arquitetura base, substituir as camadas completamente conectadas fc6 e fc7 por camadas convolucionais, alterar o filtro pool5 de $2 \times 2 - s2$ para $3 \times 3 - s1$, e usaram o algoritmo *à trous* (HOLSCHNEIDER et al., 1990) para preencher os espaços vazios. Além

disso, eles removeram todas as camadas de *dropout* e a última camada completamente conectada. Por fim, as camadas de convolução geram os resultados de mais de 8000 localizações e classificações, as quais são filtradas em um passo final de supressão de não-máximos, que elimina todos os resultados com confiança abaixo de 0,5.

Figura 5 – Comparação entre YOLO e SSD



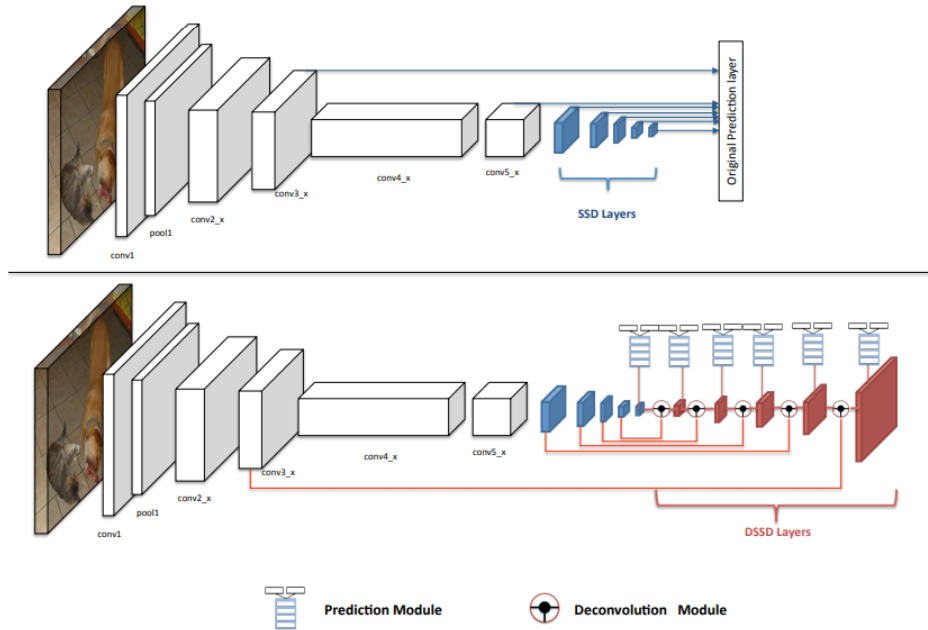
Fonte: Liu et al. (2015).

A Figura 5 mostra as diferenças entre as arquiteturas YOLO e SSD. Enquanto Redmon et al. (2015) usaram uma camada completamente conectada intermediária para fazer a localização dos objetos, Liu et al. (2015) usaram camadas de convolução sobre mapas de múltiplos tamanhos. Além disso, o SSD trabalha com *bounding-boxes* de tamanhos padrões $\{1, 2, 3, \frac{1}{2}, \frac{1}{3}\}$. Os filtros de convolução adicionais, os tamanhos padrões de *bounding-boxes* e o uso de *data-augmentation* foram cruciais na obtenção dos bons resultados.

3.3 DSSD: *Deconvolution Single-Shot Detector*

Fu et al. (2017) propuseram uma extensão do SSD. Depois dos resultados obtidos pelo SSD ao fazer localização e classificação de objetos com uma mAP de 79,5%, eles propuseram uma abordagem alternativa, usando camadas de deconvolução ao final da rede. As camadas de deconvolução tem entre seus resultados o aumento de resolução do mapa de entrada. A abordagem visou explorar esse efeito com o intuito de aumentar a mAP da classificação e localização de objetos, e, com isso, atingir uma mAP de 81,5%. Embora essa abordagem tenha uma mAP maior do que a obtida por Liu et al. (2015), ela não é rápida o bastante pra fazer localização e classificação em tempo real.

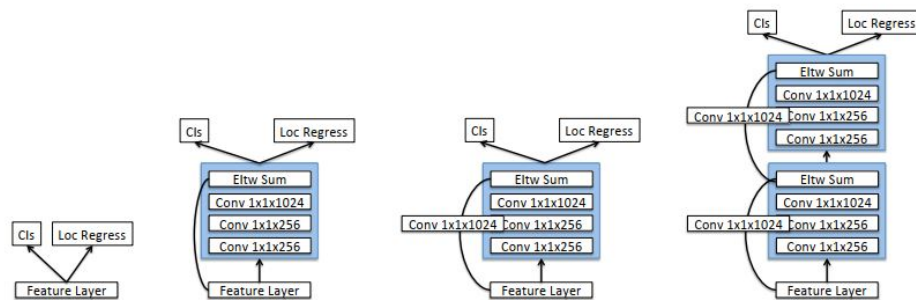
Figura 6 – Comparação entre SSD e DSSD



Fonte: Fu et al. (2017).

Nesse trabalho, foram propostas duas alterações principais no modelo SSD. A primeira delas foi a utilização da rede neural ResNet-101 (He et al., 2016). Fu et al. (2017) perceberam, porém, que apenas substituir a VGG16 pela ResNet não produziria resultados melhores. Sendo assim, após adicionar as camadas de convolução do SSD para fazer a detecção em múltiplos níveis, ele adicionou um módulo com mais algumas camadas de convolução a fim de melhorar os resultados. Os módulos propostos estão na Figura 7.

Figura 7 – Módulos de predição SSD com ResNet




Fonte: Fu et al. (2017).

Fazendo os testes, Fu et al. (2017) perceberam que os melhores resultados foram obtidos usando a terceira opção que consistem um módulo residual com uma convolução na conexão alternativa e a junção das duas entradas sendo feita por meio de uma multiplicação elemento por elemento. Neste ponto, as mudanças ainda se mostravam pouco efetivas, já que a nova SSD321 apresentava 77,1% de mAP contra 77,5% de mAP da SSD300, ao passo que a nova SSD513 apresentava 80,6% contra 79,5% da SSD512.

Tendo isso em vista, após a implementação dos módulos SSD na ResNet101, Fu et al. (2017) decidiram adicionar módulos usando camadas de deconvolução com o intuito de fazer um *upsample* nas saídas da SSD para obter mais dados. Depois de adicionar esses módulos, eles são combinados com o módulo SSD anterior para gerar a nova saída. A Figura 8 mostra como é feita essa combinação.

Figura 8 – Módulos de deconvolução



Fonte: Fu et al. (2017).

Como mencionado anteriormente, embora o DSSD tenha melhorado a mAP do SSD, ele não é aplicável para fazer a localização e classificação em tempo real. Com uma mAP de 81,5% ele consegue processar apenas 6,6 FPS. Isso se deve ao uso das deconvoluções, da ResNet 101 - que possui mais camadas, e, portanto toma mais tempo de processamento - e também ao aumento no número de *bounding boxes* geradas (43688 vs. 17080), fazendo assim com que a supressão de não-máximos leve mais tempo.

3.4 PASCAL VOC

Um grande desafio em treinar modelos de *Deep Learning* é a necessidade de um grande volume de dados classificados manualmente. Com essa necessidade, diversos trabalhos foram desenvolvidos com o objetivo de apresentar uma base de dados anotados manualmente para um conjunto de problemas específicos. Nos trabalhos de Localização e classificação, uma das bases mais utilizadas é a *PASCAL Visual Object Classes* (PASCAL VOC).

O desafio PASCAL VOC foi realizado anualmente entre os anos de 2004 e 2012, e a cada ano novas imagens e novos desafios foram propostos na área de visão computacional. Os principais desafios envolviam Localização e Classificação de Objetos, Segmentação

Semântica, *layout* humano (um desafio que consiste em detectar partes do corpo como cabeça, mãos e pés) e classificação de ações (EVERINGHAM et al., 2015).

O desafio de Localização e Classificação de objetos desde 2007 possui 20 classes distintas de objetos e a cada ano eles criaram uma nova base com mais imagens extraídas da internet. A Tabela 1 mostra as classes, o número de imagens e o número de objetos por classe nos conjuntos de treino, validação e teste.

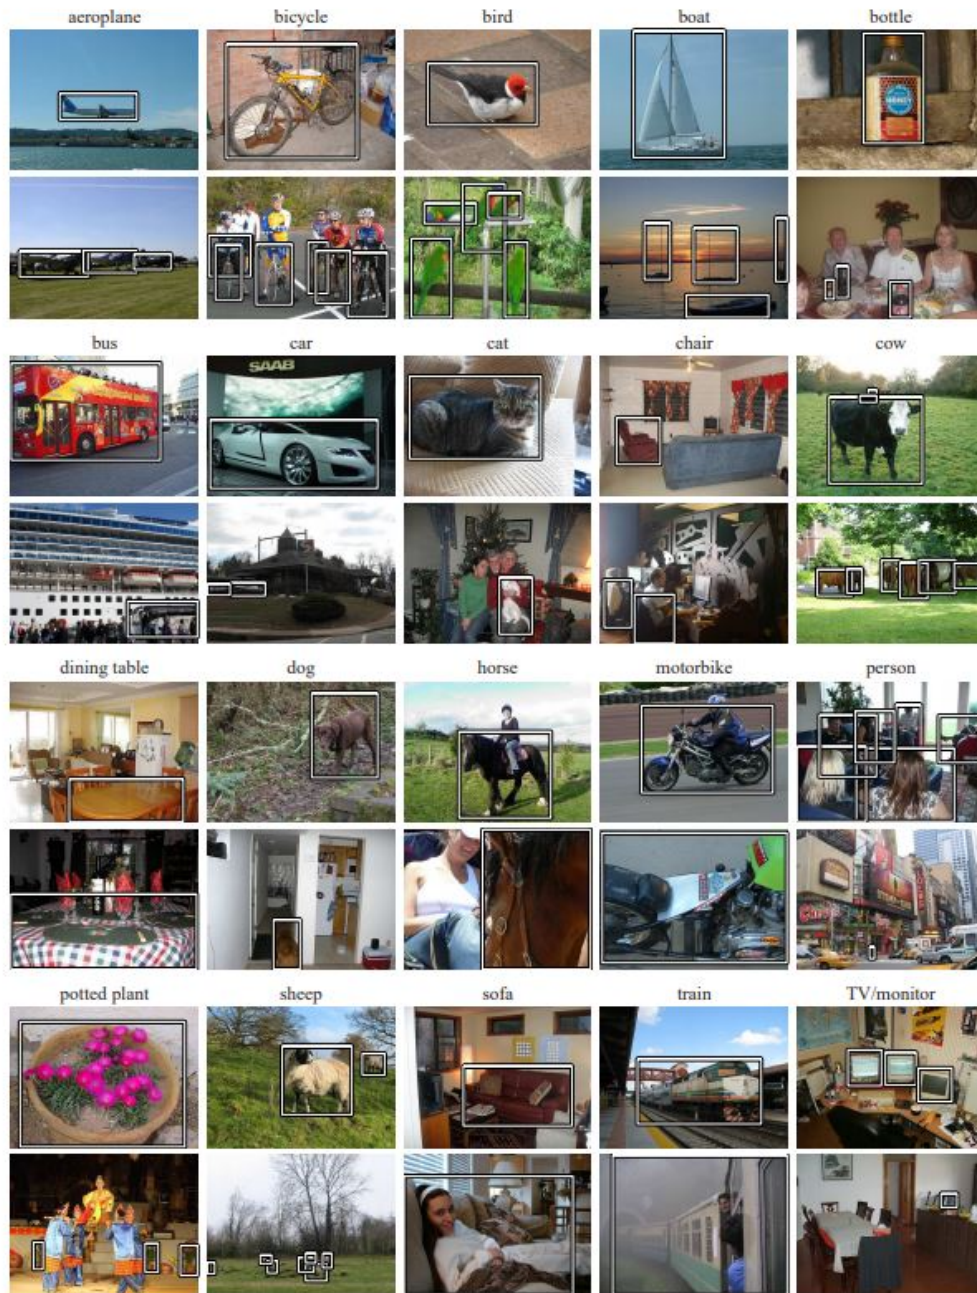
Tabela 1 – Classes de imagens do PASCAL VOC 2007

	Treino		Validação		Treino/Validação		Teste	
	imagens	Objetos	Imagens	Objetos	Imagens	Objetos	Imagens	Objetos
Avião	112	151	126	155	238	306	204	285
Bicicleta	116	176	127	177	243	353	239	282
Pássaro	180	243	150	243	330	486	282	459
Barco	81	140	100	150	181	290	172	263
Garrafa	139	253	105	252	244	505	212	469
Ônibus	97	115	89	114	186	229	174	213
Carro	376	625	337	625	713	1250	721	1201
Gato	163	186	174	190	337	376	322	358
Cadeira	224	400	221	398	445	798	417	756
Vaca	69	136	72	123	141	259	127	244
Mesa de Jantar	97	103	103	112	200	215	190	206
Cão	203	253	218	257	421	510	418	489
Cavalo	139	182	148	180	287	362	274	348
Motocicleta	120	167	125	172	245	339	222	325
Pessoa	1025	2358	983	2332	2008	4690	2007	4528
Vaso de planta	133	248	112	266	245	514	224	480
Ovelha	48	130	48	127	96	257	97	242
Sofá	111	124	118	124	229	248	223	239
Trem	127	145	134	152	261	297	259	282
Monitor/TV	128	166	128	158	256	324	299	308
Total	2501	6301	2510	6307	5011	12608	4952	12032

Fonte: Adaptado de Everingham et al. (2010).

Analisando a tabela é possível perceber que a base é desbalanceada. A classe pessoa, por exemplo, está presente em mais de 1000 imagens e tem mais de 2000 instâncias apenas no conjunto de treinamento. Enquanto isso, a classe ovelha aparece apenas 130 vezes em 48 imagens no conjunto de treinamento. Esse desbalanceamento pode ser um desafio durante o treinamento caso o modelo não seja robusto. A Figura 9 mostra exemplos das classes presentes na PASCAL VOC 2007.

Figura 9 – Exemplos de imagens da PASCAL VOC 2007



Fonte: Everingham et al. (2010).

3.4.1 PASCAL VOC 2012

Em 2012 foi lançado uma outra versão da PASCAL VOC. Essa edição da competição tinha uma base de dados maior e mais robusta, embora ainda mantivesse as mesmas 20 classes da base de 2007.

4 PROPOSTA TÉCNICA

4.1 Metodologia

A seguir, serão definidos os passos necessários para a elaboração do trabalho proposto.

4.1.1 *Levantamento Bibliográfico*

Nesta fase será feito um levantamento na literatura de tudo o que é julgado necessário para realizar o trabalho proposto. Será feito um estudo para compreensão da arquitetura DenseNet (Huang et al., 2017). Além disso, serão feitos estudos com métodos da literatura como YOLO (REDMON et al., 2015), SSD (LIU et al., 2015) e DSSD (FU et al., 2017). Serão feitos também estudos para analisar o conteúdo da base de dados para testes. A base utilizada será a PASCAL VOC (EVERINGHAM et al., 2015). Além disso, nessa etapa serão levantadas as formas de avaliar os resultados dos algoritmos.

4.1.2 *Testes e avaliações com métodos da literatura*

Nesta etapa serão feitos os testes com os métodos já implementados na literatura. O objetivo é compreender o funcionamento, levantar os principais obstáculos nas respectivas implementações e selecionar as melhores tecnologias para a realização do projeto proposto. Nesta etapa também serão testados os algoritmos para avaliar os resultados obtidos, propostos por Everingham et al. (2015) e por Lin et al. (2014).

4.1.3 *Desenvolvimento do protótipo inicial*

A proposta é desenvolver um protótipo inicial usando a arquitetura da DenseNet 121 apresentada por Huang et al. (2017) com alterações. As alterações a ser feitas são a remoção da camada final de classificação e a inserção de camadas intermediárias de convolução para realizar a localização dos objetos em diferentes escalas, como apresentado por Liu et al. (2015). Além disso, serão aplicadas as mesmas modificações aplicadas inicialmente na ResNet 101 para gerar o primeiro modelo proposto por (FU et al., 2017).

4.1.4 Desenvolvimento da arquitetura final usando deconvolução

Depois de alterar a arquitetura para fazer a detecção em múltiplas escalas usando convolução, será feita uma nova modificação da arquitetura, acrescentando camadas de deconvolução. Para cada camada de deconvolução é acrescentado um módulo de predição, que fará a localização e a classificação dos objetos. O acréscimo das camadas de deconvolução e dos novos módulos de predição seguem o modelo proposto por Fu et al. (2017).

4.1.5 Avaliação dos resultados e comparação com o Estado da Arte

Por fim, será feita a avaliação dos resultados dos métodos propostos e a comparação dos mesmos com os resultados do estado da arte. Essas avaliações serão feitas com base nas métricas que serão apresentadas na Sub-seção 4.1.1. O objetivo é dizer o quão efetivo foi a utilização de uma arquitetura de CNN mais moderna e avançada com métodos já conhecidos na resolução do problema de localização e classificação.

5 EXPERIMENTOS

5.1 SSD

A primeira implementação consiste em adaptar a DenseNet 121 para realizar as tarefas de localização e classificação. Nesse estágio foi feita uma pequena alteração com relação aos modelos propostos por Liu et al. (2015) e por Fu et al. (2017). Enquanto que Liu et al. (2015) usou imagens de tamanho 300×300 e Fu et al. (2017) usou imagens de tamanho 321×321 , foi usado nesse trabalho imagens de 311×311 .

O motivo é que, embora a DenseNet possua as mesmas características de *downsample* (por meio de convolução ou *pooling*) que a ResNet, a implementação da SSD por Fu et al. (2017) usa *padding* válido para todas as camadas de *downsample*. Isso faz com que, caso o tamanho de saída da camada de *downsample* não seja inteiro, uma parte seja cortada, podendo causar perda de informação. Sendo assim, foi feita a opção por uma imagem com tamanho menor e o uso de *padding* equivalente, de forma a evitar o corte.

Além dessas modificações, é necessário mudar algumas coisas na arquitetura da rede DenseNet121. A primeira delas é que a SSD utiliza ramificações de diferentes níveis para fazer as predições de forma mais precisa. Sendo assim, a primeira alteração é que no segundo bloco de transição é criada uma ramificação fazendo regularização L2. Além disso, a camada de *pooling* do último bloco de transição é substituída por um bloco 3×3 com strides igual a 1. Por fim, no final da rede as camadas de *pooling* global e softmax são removidas e essa saída é a segunda ramificação da SSD. Depois disso, são adicionados mais dois blocos com camadas de convolução, uma 1×1 seguida de um 3×3 com *stride* 2. Por fim, mais dois blocos, com as mesmas camadas, porém, as camadas 3×3 com *stride* igual a 1.

5.1.1 Treinamento

A rede foi inicializada com os pesos da DenseNet121 treinada na ImageNet, e as camadas adicionais foram inicializadas com o método *He normal* proposto por He et al. (2015). O algoritmo de treinamento selecionado foi o Adam, proposto por Kingma e Ba (2014) com os seguintes hiperparâmetros:

- $\alpha = 5 \times 10^{-5}$;
- $\beta_1 = 0,9$;


- $\beta_2 = 0,999$;
- $\epsilon = 1 \times 10^{-8}$.

Além disso, o treinamento ocorreu em um total de 400 épocas, cada época com 1000 iterações e cada iteração com um lote de processamento de 12 imagens. Após 200 épocas de treinamento, a taxa de aprendizado caiu para 5×10^{-6} e após mais 100 épocas, caiu para 5×10^{-7} . As bases de dados usadas para os testes foram a PASCAL VOC 2007 e 2012. Para treinamento foram usadas as imagens do conjunto de treino e validação de ambas as bases, e para validação dos testes foi utilizada a base de testes de 2007. Os testes serão feitos na base de 2012.

5.1.2 Avaliação Qualitativa

Depois do treinamento, foram feitos alguns experimentos com imagens aleatórias do conjunto separado para validação para avaliar os resultados obtidos pelo método. Embora o método consiga fazer a detecção e a classificação dos objetos, foram percebidas algumas dificuldades.


Figura 10 – Resultado dos testes 1



Fonte: Elaborado pelo autor.

Na Figura 10 o modelo detectou a pessoa sentada na cadeira e a cadeira no fundo, porém não detectou o cão deitado no chão. Isso pode refletir um pouco de dificuldade em perceber objetos menores ou que não estejam tão centralizados. Além disso, Embora a pessoa sentada esteja bem nítida na imagem, o modelo não conseguiu ter 100% de confiança que era uma pessoa.

Figura 11 – Resultado dos testes 2



Fonte: Elaborado pelo autor.

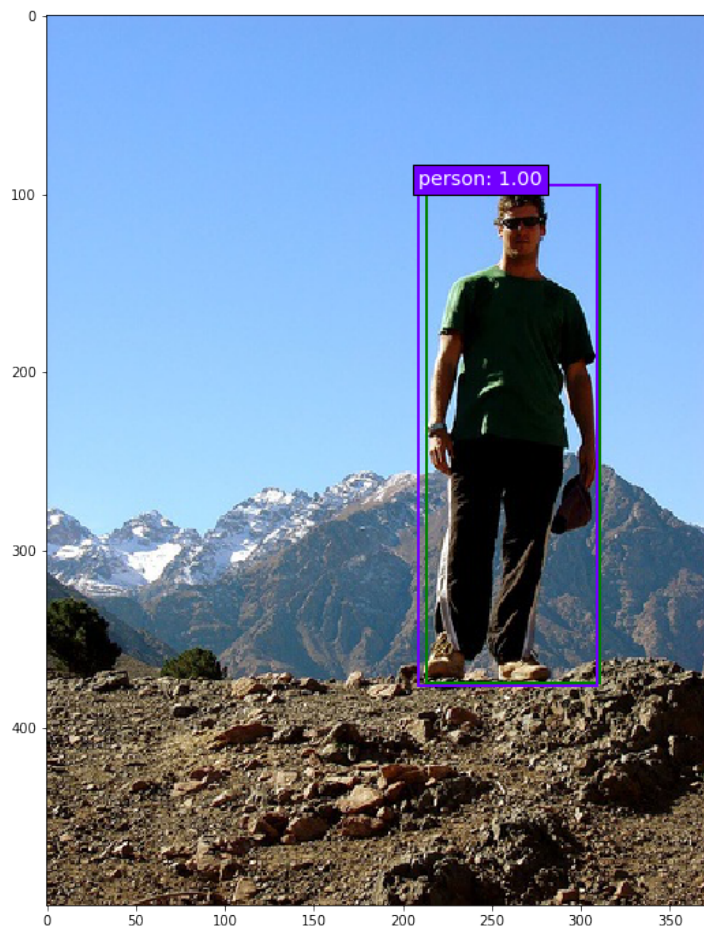
Na Figura 11 percebemos mais uma vez o problema da confiança baixa. Além disso, a *bounding box* do cão de trás esta pegando apenas a cabeça, sendo que outras partes do corpo dele estão expostas (ainda que sobrepostas parcialmente).

Figura 12 – Resultado dos testes 3




Fonte: Elaborado pelo autor.

Na Figura 12, mostra mais uma vez uma nítida dificuldade do modelo em perceber objetos mais distantes. A imagem possui 9 objetos delimitados no *ground-truth* e o modelo conseguiu detectar apenas 2. Ele não consegue perceber nem a mesa de jantar e nem as pessoas mais ao fundo. Além disso, as duas pessoas que estão em pé no canto direito da Figura foram percebidas como apenas uma pelo modelo.

Figura 13 – Resultado dos testes 4

Fonte: Elaborado pelo autor.

A Figura 13 é bem simples e o único objeto presente está bem nítido, então o modelo consegue percebê-lo com a confiança de 100%.

Figura 14 – Resultado dos testes 5

Fonte: Elaborado pelo autor.

Já a Figura 14 mostra um fenômeno diferente: além de detectar o único objeto presente no *ground-truth* com a confiança alta, ele também detecta uma outra instância do mesmo objeto ao fundo. Isso significa que embora o modelo tenha um pouco de dificuldade com objetos que não estão em destaque, essa dificuldade não é tão crítica e existe uma certa robustês.

5.1.3 Avaliação Quantitativa

Depois dos experimentos, foram feitos os testes para avaliar de forma numérica os resultados do modelo e comparar com o estado da arte. O resultado final apontou um mAP de 72,6%.

Tabela 2 – Comparação SSD300, SSD321 e SSD311

Objeto	SSD311(nosso)	SSD300	SSD321
Avião	80,8%	79,5%	76,3%
Bicicleta	82,3%	83,9%	84,6%
Pássaro	66,3%	76%	79,3%
Barco	61,3%	69,6%	64,6%
Garrafa	31,2%	57,5%	47,2%
Ônibus	82,8%	87%	85,4%
Carro	86%	85,7%	84%
Gato	85,8%	88,1%	88,8%
Cadeira	52,9%	60,3%	60,1%
Vaca	75%	81,5%	82,6%
Mesa de Jantar	72,4%	77%	76,9%
Cão	77,4%	86,1%	86,7%
Cavalo	86,2%	87,5%	87,2%
Motocicleta	86,3%	84%	85,4%
Pessoa	77,4%	79,4%	79,1%
Vaso de planta	42,6%	52,3%	50,8%
Ovelha	69,9%	77,9%	77,2%
Sofá	77,2%	79,5%	82,6%
Trem	84,3%	87,6%	87,3%
Monitor/TV	73%	76,8%	76,6%
Total	72,6%	77,5%	77,1%

Fonte: Elaborado pelo autor.

O resultado evidencia algumas dificuldades que o modelo apresentou conforme visto na seção 5.1.2 e não está no mesmo nível que os resultados obtidos por Liu et al. (2015) e Fu et al. (2017).

Esse problema pode ser justificado por dois fatores principais. Por limitações computacionais, só foi possível fazer o treinamento com 12 imagens por iteração, enquanto que os modelos de Liu et al. (2015) e Fu et al. (2017) treinaram com 32 imagens por

iteração. Pelo fato do número de imagens por iteração ser menor, foi necessário treinar por mais iterações o que pode acarretar em um segundo problema: *overfitting*, que é quando o modelo começa a aprender os dados específicos ao invés de aprender a fazer a classificação de forma mais generalista.

6 CONCLUSÃO

Com base no conteúdo apresentado, podemos concluir que, embora um modelo de *deep learning* possa obter bons resultados em tarefas de classificação e localização de objetos, é necessário ter cuidado com uma série de fatores antes de fazer a implementação, pois isso pode afetar os resultados de uma forma negativa. É importante conhecer bem o modelo implementado, estudar os hiper-parâmetros e fazer vários testes para garantir que o resultado saia como o esperado.

6.1 Trabalhos Futuros

Como trabalhos futuros, espera-se fazer um teste com o modelo desenvolvido treinando-o com mais imagens por iteração. Além disso, espera-se também fazer uma implementação usando as camadas de deconvolução.

REFERÊNCIAS

- APTÉ, C.; WEISS, S. Data mining with decision trees and decision rules. *FUTURE GENERATION COMPUTER SYSTEMS*, v. 13, n. 2, p. 197 – 210, 1997. ISSN 0167-739X. Tradução nossa. Disponível em: <<<http://www.sciencedirect.com/science/article/pii/S0167739X97000216>>>.
- ARNOLD, L. et al. An introduction to deep learning. In: *EUROPEAN SYMPOSIUM ON ARTIFICIAL NEURAL NETWORKS (ESANN)*. [S.l.: s.n.], 2011. Tradução nossa.
- Caelles, S. et al. One-shot video object segmentation. In: *2017 IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR)*. [S.l.: s.n.], 2017. p. 5320–5329. ISSN 1063-6919. Tradução nossa.
- Deng, J. et al. Imagenet: A large-scale hierarchical image database. In: *2009 IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION*. [S.l.: s.n.], 2009. p. 248–255. ISSN 1063-6919. Tradução nossa.
- DENG, L.; YU, D. Deep learning: Methods and applications. *FOUNDATIONS AND TRENDS® IN SIGNAL PROCESSING*, v. 7, n. 3–4, p. 197–387, 2014. Tradução nossa.
- DO, T.-N.; POULET, F. Parallel multiclass logistic regression for classifying large scale image datasets. In: THI, H. A. L.; NGUYEN, N. T.; DO, T. V. (Ed.). *ADVANCED COMPUTATIONAL METHODS FOR KNOWLEDGE ENGINEERING*. Cham: Springer International Publishing, 2015. p. 255–266. ISBN 978-3-319-17996-4.
- DOSUALDO, D. G. INVESTIGAÇÃO DE REGRESSÃO NO PROCESSO DE MINERAÇÃO DE DADOS. Dissertação de Mestrado — Universidade de São Paulo, Maio 2003.
- EVERINGHAM, M. et al. The pascal visual object classes challenge: A retrospective. *INTERNATIONAL JOURNAL OF COMPUTER VISION*, v. 111, n. 1, p. 98–136, jan 2015. Tradução nossa.
- EVERINGHAM, M. et al. The pascal visual object classes (voc) challenge. *INTERNATIONAL JOURNAL OF COMPUTER VISION*, v. 88, p. 303–338, 06 2010.
- FERREIRA, A. dos S. REDES NEURAS CONVOLUCIONAIS PROFUNDAS NA DETECÇÃO DE PLANTAS DANINHAS EM LAVOURA DE SOJA. Dissertação (Dissertação (Mestrado)) — Universidade Federal do Mato Grosso do Sul, Pos-Graduação em Ciências da Computação, 2017.
- FU, C. et al. DSSD : Deconvolutional single shot detector. *CoRR*, abs/1701.06659, 2017. Tradução nossa. Disponível em: <<<http://arxiv.org/abs/1701.06659>>>.
- FUKUSHIMA, K. Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position. *BIOLOGICAL CYBERNETICS*, v. 36, n. 4, p. 193–202, Apr 1980. ISSN 1432-0770. Tradução nossa. Disponível em: <<<https://doi.org/10.1007/BF00344251>>>.

HE, K. et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. In: PROCEEDINGS OF THE IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV). [S.l.: s.n.], 2015.

He, K. et al. Deep residual learning for image recognition. In: 2016 IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR). [S.l.: s.n.], 2016. p. 770–778. ISSN 1063-6919. Tradução nossa.

HOLSCHNEIDER, M. et al. A real-time algorithm for signal analysis with the help of the wavelet transform. In: COMBES, J.-M.; GROSSMANN, A.; TCHAMITCHIAN, P. (Ed.). WAVELETS. Berlin, Heidelberg: Springer Berlin Heidelberg, 1990. p. 286–297. ISBN 978-3-642-75988-8.

Huang, G. et al. Densely connected convolutional networks. In: 2017 IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR). [S.l.: s.n.], 2017. p. 2261–2269. ISSN 1063-6919. Tradução nossa.

JOST, I. APLICAÇÃO DE *DEEP LEARNING* EM DADOS REFINADOS PARA MINERAÇÃO DE OPINIÕES. Dissertação (Mestrado) — Universidade do Vale do Rio dos Sinos, Programa Interdisciplinar de Pós-Graduação em Computação Aplicada, São Leopoldo., 2015.

KINGMA, D.; BA, J. Adam: A method for stochastic optimization. INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 12 2014.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. Imagenet classification with deep convolutional neural networks. In: PROCEEDINGS OF THE 25TH INTERNATIONAL CONFERENCE ON NEURAL INFORMATION PROCESSING SYSTEMS - VOLUME 1. USA: Curran Associates Inc., 2012. (NIPS'12), p. 1097–1105. Tradução nossa. Disponível em: <<<http://dl.acm.org/citation.cfm?id=2999134.2999257>>>.

Lan, W. et al. Pedestrian detection based on yolo network model. In: 2018 IEEE INTERNATIONAL CONFERENCE ON MECHATRONICS AND AUTOMATION (ICMA). [S.l.: s.n.], 2018. p. 1547–1551. ISSN 2152-744X. Tradução nossa.

Lecun, Y. et al. Gradient-based learning applied to document recognition. PROCEEDINGS OF THE IEEE, v. 86, n. 11, p. 2278–2324, Nov 1998. ISSN 0018-9219. Tradução nossa.

LIN, T. et al. Microsoft COCO: common objects in context. CoRR, abs/1405.0312, 2014. Tradução nossa. Disponível em: <<<http://arxiv.org/abs/1405.0312>>>.

LIU, W. et al. SSD: single shot multibox detector. CoRR, abs/1512.02325, 2015. Tradução nossa. Disponível em: <<<http://arxiv.org/abs/1512.02325>>>.

LONG, J.; SHELHAMER, E.; DARRELL, T. Fully convolutional networks for semantic segmentation. CoRR, abs/1411.4038, 2014. Tradução nossa. Disponível em: <<<http://arxiv.org/abs/1411.4038>>>.

MONARD, M. C.; BARANAUSKAS, J. A. Conceitos sobre aprendizado de máquina. SISTEMAS INTELIGENTES-FUNDAMENTOS E APLICAÇÕES, v. 1, n. 1, 2003.

Noh, H.; Hong, S.; Han, B. Learning deconvolution network for semantic segmentation. In: 2015 IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV). [S.l.: s.n.], 2015. p. 1520–1528. ISSN 2380-7504. Tradução nossa.

PEREIRA, J. C.; GARSON, S.; ARAÚJO, E. G. Construção de um modelo para o preço de venda de casas residenciais na cidade de sorocaba-sp. REVISTA GEPROS, n. 4, p. 153, 2012.

REDMON, J. et al. You only look once: Unified, real-time object detection. CoRR, abs/1506.02640, 2015. Tradução nossa. Disponível em: <<<http://arxiv.org/abs/1506.02640>>>.

Ren, P.; Fang, W.; Djahel, S. A novel yolo-based real-time people counting approach. In: 2017 INTERNATIONAL SMART CITIES CONFERENCE (ISC2). [S.l.: s.n.], 2017. p. 1–2. Tradução nossa.

Ren, S. et al. Faster r-cnn: Towards real-time object detection with region proposal networks. IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE, v. 39, n. 6, p. 1137–1149, June 2017. ISSN 0162-8828.

SANTOS, A. de M. Tese de Doutorado, INVESTIGANDO A COMBINAÇÃO DE TÉCNICAS DE APRENDIZADO SEMISSUPERVISIONADO E CLASSIFICAÇÃO HIERÁRQUICA MULTIRRÓTULO. [S.l.]: Universidade Federal do Rio Grande do Norte, 2012.

SIMONYAN, K.; ZISSERMAN, A. Very deep convolutional networks for large-scale image recognition. CoRR, abs/1409.1556, 2014. Tradução nossa.

VOIGTLAENDER, P.; LEIBE, B. Online adaptation of convolutional neural networks for video object segmentation. CoRR, abs/1706.09364, 2017. Tradução nossa. Disponível em: <<<http://arxiv.org/abs/1706.09364>>>.

Yang, W.; Jiachun, Z. Real-time face detection based on yolo. In: 2018 1ST IEEE INTERNATIONAL CONFERENCE ON KNOWLEDGE INNOVATION AND INVENTION (ICKII). [S.l.: s.n.], 2018. p. 221–224. Tradução nossa.